

Questão 1: Governança de Dados e LGPD

A)

Data Owner (Proprietário dos Dados)

- **Cargo sugerido na vinícola:** Diretor de Operações (ou Diretor de Enologia).
- **O conceito:** É o líder de negócios que responde legal, estratégica e financeiramente por aquele domínio de dados. Ele é o "dono" da regra de negócio e aprova quem pode ou não acessar as informações.
- **Justificativa na prática:** O Diretor de Operações assume este papel pois é quem responde diretamente pelos resultados do negócio. A planilha concentra informações críticas que sustentam a vinícola: de um lado, a cadeia de suprimentos (e-mails de fornecedores); do outro, o segredo industrial e a qualidade do produto (análises químicas). Em caso de vazamento da composição de um lote ou de multas por violação da LGPD, o impacto estratégico e financeiro recai sobre a operação. Exatamente por assumir esse risco de negócio, o diretor deve ser a autoridade com a palavra final para ditar as regras e aprovar quem tem ou não permissão de acesso a esses ativos.

Data Steward (Curador/Guardião dos Dados)

- **Cargo sugerido na vinícola:** Coordenador de Controle de Qualidade (ou Enólogo Sênior).
- **O conceito:** É o especialista que conhece o significado da informação. Ele garante a qualidade, a padronização e a usabilidade dos dados no dia a dia, atuando como a ponte entre o negócio e a TI.
- **Justificativa na prática:** É quem detém o conhecimento técnico necessário para validar os dados no dia a dia. É ele quem consegue analisar e confirmar se o resultado de uma análise química (como os níveis de pH e acidez) está correto e se o fornecedor registrado para aquele lote realmente faz sentido. A função dele na prática é auditar essa planilha, definindo regras claras de preenchimento — como padronizar as unidades de medida — e cobrando a equipe para que os contatos dos fornecedores estejam sempre atualizados. Isso mantém a qualidade da base e evita que a operação pare por conta de informações erradas.

Data Custodian (Custodiante dos Dados)

- **Cargo sugerido na vinícola:** Analista de TI (ou Administrador da Rede).
- **O conceito:** É o responsável técnico pela infraestrutura física ou em nuvem onde o dado "mora". Ele cuida do armazenamento, segurança e disponibilidade, sem necessariamente entender o conteúdo do dado.
- **Justificativa na prática:** Na prática, ele não precisa entender o que os dados significam. O dever dele é garantir que a planilha fique salva em um ambiente seguro, configurar backups automáticos para evitar perdas e aplicar os métodos de proteção, como a criptografia. É ele quem implementa as travas no sistema para garantir que

apenas as pessoas previamente autorizadas pelo Data Owner consigam ler ou editar o documento.

B)

Classificação do E-mail do Fornecedor

- **Nível de Sensibilidade:** Interno.
- **Justificativa:** O e-mail de contato é uma informação de rotina essencial para o fluxo de trabalho da vinícola. Embora seja um dado pessoal protegido pela LGPD, ele não é enquadrado como "Sensível", uma vez que a lei restringe essa categoria estrita a informações sobre origem racial, saúde ou opinião política. Portanto, é um dado de uso interno que requer cuidado, mas cujo vazamento não expõe intimidades críticas.

Classificação das Análises Químicas

- **Nível de Sensibilidade:** Confidencial.
- **Justificativa:** Os resultados químicos representam o segredo industrial da vinícola. O vazamento dessa composição exata causa um impacto estratégico e financeiro altíssimo, pois compromete diretamente a vantagem competitiva e o diferencial do produto no mercado.

Diferença de Tratamento e Controle de Acesso A distinção no tratamento entre esses dois tipos de dados baseia-se na amplitude de acesso e no rigor da segurança aplicada. O e-mail do fornecedor (Interno) exige um acesso mais amplo, precisando circular entre os setores de compras, financeiro e enologia, o que demanda proteções operacionais padrão. Por outro lado, as análises químicas (Confidenciais) operam sob o princípio da restrição extrema: só devem ser vistas por quem formula ou aprova o vinho. Consequentemente, a governança sobre esses dados exige controles muito mais rígidos, como criptografia avançada e um registro (log) estrito para auditar exatamente quem visualizou ou editou essa informação.

C)

O fornecedor está exercendo o direito de **eliminação de dados**, previsto no art. 18 da LGPD, inciso IV já que a relação comercial acabou e a manutenção do seu e-mail na planilha perdeu a finalidade.

Já na época da coleta original, a base legal do art. 7º que justificou pedir esse e-mail foi a **execução de contrato**, inciso V da LGPD, afinal, a vinícola precisava desse contato para poder negociar, comprar os insumos e fazer o faturamento. O único ponto de atenção prático aqui é que, antes de apagar o contato imediatamente, a vinícola precisa confirmar se não é

obrigada a manter esse histórico guardado por mais um tempo só para cumprir alguma obrigação fiscal ou legal.

Questão 2 : Amostragem, Distribuição e Medidas Descritivas

A)

A avaliação restrita às 30 primeiras garrafas da planilha configura uma amostragem de conveniência, o que compromete a validade da inspeção ao quebrar o princípio da aleatoriedade e introduzir viés de seleção. Como o lote é um *blend* composto por três cultivares distintas em proporções desiguais, a população é estruturalmente heterogênea e as primeiras garrafas podem não representar o todo.

Para solucionar esse problema e garantir a representatividade, a técnica correta é a **amostragem probabilística estratificada proporcional**. Esse método divide o lote total em três estratos (um para cada cultivar) e realiza o sorteio aleatório das 30 garrafas dentro de cada grupo, respeitando rigorosamente a proporção de cada uva na composição do lote. Assim, garante-se que a amostra final reflita fielmente as características da produção inteira.

B)

Média vs. Mediana

A afirmação do colega está incorreta. A média não é a medida mais robusta, muito pelo contrário: ela é extremamente sensível a valores atípicos (outliers). Se houver um vinho com teor alcoólico muito fora do padrão ou um erro de digitação na planilha, a média será distorcida por esse valor. A mediana é preferível justamente nessas situações de dados com outliers ou distribuições assimétricas, pois ela aponta o valor típico central sem se deixar influenciar por esses extremos.

Desvio-Padrão vs. Coeficiente de Variação (CV)

O problema do desvio-padrão isolado é que ele herda a mesma unidade de medida da variável analisada. Portanto, ele não serve para comparar a variação do teor alcoólico (medido em %) com a acidez (medida em g/L), por exemplo. O Coeficiente de Variação (CV) permite uma conclusão muito mais justa porque ele normaliza o desvio-padrão pela média, gerando uma taxa de dispersão relativa em porcentagem. Isso nos permite bater o olho e ver qual característica química do vinho é mais homogênea, mesmo estando em escalas totalmente diferentes.

C)

Comportamento das Médias Amostrais e o TCL

O desvio-padrão das médias amostrais é menor porque, ao tirar a média de 30 garrafas juntas, os valores extremos (muito altos e muito baixos) acabam se compensando e se anulando. Por causa disso, as médias variam bem menos do que analisar garrafas isoladas.

O teorema que garante esse resultado é o **Teorema Central do Limite (TCL)**. A relação matemática entre eles é: Desvio-padrão das médias = $\sigma / \sqrt{n}$

(onde " σ " é o desvio-padrão da população e " n " é o tamanho da amostra).

Questão 3 : Correlação e Testes de Hipótese

A)

A interpretação está incorreta porque o valor-p não mede a probabilidade de a hipótese alternativa ser verdadeira. Ele sempre parte da premissa de que a Hipótese Nula (H_0) é a realidade. O correto seria dizer: se não houvesse diferença real nenhuma, teríamos apenas 3% de chance de observar os dados extremos que encontramos na amostra.

Sobre os erros de decisão, suponha que H_0 seja "os cultivares A e B têm a mesma produtividade":

- **Erro Tipo I (Falso Positivo):** É rejeitar a H_0 quando ela é verdadeira. Na prática: o teste diz que o Cultivar B é melhor, a vinícola gasta uma fortuna no replantio, mas na realidade eles produzem exatamente a mesma coisa.
- **Erro Tipo II (Falso Negativo):** É falhar em rejeitar a H_0 quando ela é falsa. Na prática: o Cultivar B realmente é mais produtivo, mas o teste não acusa. A vinícola ignora a uva e perde a oportunidade de aumentar sua produção.

B)

Aplicar o teste de significância de Pearson nessas condições é inadequado porque esse teste exige estritamente que os dados sigam uma distribuição normal. Como o teste de Shapiro-Wilk rejeitou a normalidade ($p < 0,05$), o cálculo estatístico do Pearson perde a sua validade, podendo gerar um p-valor não confiável.

Quando isso acontece, devemos migrar para métodos não paramétricos. As duas alternativas principais são:

- **Coefficiente de Spearman (ρ):** Em vez de usar os números puros das análises, ele converte os dados em um ranking (postos) e avalia se a ordem de uma variável acompanha a da outra. É uma ótima opção para provar relações monotônicas.
- **Coefficiente de Kendall (τ):** Faz a análise calculando a proporção de pares concordantes e discordantes. É a alternativa mais robusta e indicada quando a amostra é pequena ou quando existem muitos empates na base de dados (várias garrafas com a mesma medição).

C)

É fundamental distinguir a significância estatística da relevância prática. Considerando o nosso *dataset* de 178 amostras, suponha que o teste aponte uma diferença estatisticamente significativa ($p < 0,05$) ao comparar dois processos, onde o primeiro gera 13,00% de teor

alcoólico e o segundo 13,05%. Embora a matemática comprove que essa leve variação de 0,05% realmente existe e não é obra do acaso, na rotina da vinícola ela carece de qualquer relevância prática (Tamanho do Efeito). Uma diferença tão ínfima é completamente imperceptível ao paladar do consumidor e está bem abaixo da margem de tolerância exigida pela legislação de rotulagem, demonstrando que o resultado, mesmo sendo estatisticamente válido, não justifica qualquer mudança operacional ou de custos para o negócio.

Questão 4 : Amostragem Estratificada e Teorema Central do Limite

```
import matplotlib.pyplot as plt
```

```
import numpy as np
```

```
import pandas as pd
```

```
# 1. Carregando o dataset
```

```
df = pd.read_csv('wine_dataset.csv')
```

```
# --- ITEM (A): Amostragem Estratificada Proporcional (20% por cultivar) ---
```

```
amostra_estratificada = df.groupby('cultivar', group_keys=False).apply(
```

```
    lambda x: x.sample(frac=0.2, random_state=42)
```

```
)
```

```
n_amostra = len(amostra_estratificada)
```

```
print(f'Tamanho da amostra estratificada (n): {n_amostra}')
```

```
# --- ITEM (B): Comparação visual (População vs Amostra) para 'proline' ---
```

```
plt.figure(figsize=(10, 5))
```

```
plt.hist(  
    df['proline'],  
    bins=12,  
    color='gray',  
    alpha=0.5,  
    edgecolor='black',  
    label='População Completa (178)',  
)  
  
plt.hist(  
    amostra_estratificada['proline'],  
    bins=12,  
    color='purple',  
    alpha=0.7,  
    edgecolor='black',  
    label=f'Amostra Estratificada (n={n_amostra})',  
)
```

```
plt.title('Comparação da Variável Proline: População vs Amostra Estratificada')
```

```
plt.xlabel('Teor de Proline')
```

```
plt.ylabel('Frequência')
```

```
plt.legend()
```

```
plt.grid(True, linestyle='--', alpha=0.6)
```

```
plt.show()
```

```
# --- ITEM (C): 1.000 Reamostragens com reposição (Bootstrap) e TCL ---
```

```
np.random.seed(42)
```

```
medias_reamostragem = []
```

```
for _ in range(1000):
```

```
    amostra_bootstrap = np.random.choice(  
        df['proline'], size=n_amostra, replace=True  
    )
```

```
    medias_reamostragem.append(np.mean(amostra_bootstrap))
```

```
# Cálculos estatísticos para o TCL
```

```
std_observado_medias = np.std(medias_reamostragem, ddof=1)
```

```
std_populacao = np.std(df['proline'], ddof=1)
```

```
erro_padrao_teorico = std_populacao / np.sqrt(n_amostra)
```

```
proporcao = std_populacao / std_observado_medias
```

```
print(f'Desvio-padrão observado das médias: {std_observado_medias:.2f}')
```

```
print(f'Erro-padrão teórico (TCL): {erro_padrao_teorico:.2f}')
```

```
print(f'O desvio populacional é cerca de {proporcao:.1f} vezes maior.')
```

```
# Plotando o histograma das 1.000 médias

plt.figure(figsize=(9, 5))

plt.hist(

    medias_reamostragem,

    bins=25,

    color='teal',

    edgecolor='black',

    alpha=0.8,

)

plt.axvline(

    np.mean(df['proline']),

    color='red',

    linestyle='dashed',

    linewidth=2,

    label='Média da População',

)

plt.title('Histograma das Médias de 1.000 Reamostragens (Proline)')



plt.xlabel('Média Amostral de Proline')

plt.ylabel('Frequência')

plt.legend()

plt.grid(True, linestyle='--', alpha=0.6)
```

```
plt.show()
```



A aplicação de 1.000 reamostragens evidenciou empiricamente os fundamentos do Teorema Central do Limite (TCL). Observou-se que a variabilidade das médias amostrais decresce de forma previsível; o desvio-padrão populacional apresentou-se aproximadamente 6 vezes maior que o desvio-padrão das médias amostrais (erro-padrão observacional perfeitamente alinhado ao cálculo teórico de $\sigma/\sqrt{n}$). Com base na análise visual dos histogramas e no comportamento distributivo, conclui-se que a amostra estratificada elaborada é altamente representativa da população original em relação à variável *proline*, preservando com fidelidade a forma geral e as proporções da curva populacional original sem introduzir viés de amostragem.

Questão 5 : Medidas de Posição, Dispersão e Outliers

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
# Carregando os dados
```

```
df = pd.read_csv('wine_dataset.csv')
```

```
colunas_quimicas = df.columns.drop('cultivar')
```

```
# =====
```

```
# ITEM (a): Medidas, CV e Top 3 Variáveis
```

```
# =====
```

```
media = df.groupby('cultivar')[colunas_quimicas].mean()
```

```
desvio = df.groupby('cultivar')[colunas_quimicas].std()
```

```
mediana = df.groupby('cultivar')[colunas_quimicas].median()
```

```
# Coeficiente de Variação (%)
```

```
cv = (desvio / media) * 100
```

```
# Pegando as 3 variáveis com maior média de CV
```

```
cv_medio_por_variavel = cv.mean(axis=0)
```

```
top_3_vars = cv_medio_por_variavel.nlargest(3).index.tolist()
```

```
print('--- ITEM (A): TOP 3 VARIÁVEIS COM MAIOR CV MÉDIO ---')
```

```
for i, var in enumerate(top_3_vars, 1):
```

```
    print(f'{i}. {var}')
```

```
print('\n')
```

```
# =====
```

```
# ITEM (b): Contagem de Outliers (1.5 x IQR)
```

```
# =====
```

```
resultados_outliers = {}
```

```
for var in top_3_vars:
```

```
    resultados_outliers[var] = {}
```

```
    for cultivar, group in df.groupby('cultivar'):
```

```
        Q1 = group[var].quantile(0.25)
```

```
        Q3 = group[var].quantile(0.75)
```

```
        IQR = Q3 - Q1
```

```
limite_inferior = Q1 - 1.5 * IQR
```

```
limite_superior = Q3 + 1.5 * IQR
```

```
# Filtrando e contando os outliers
```

```
outliers = group[(group[var] < limite_inferior) | (group[var] > limite_superior)]
```

```
resultados_outliers[var][cultivar] = len(outliers)
```

```
print('--- ITEM (B): CONTAGEM DE OUTLIERS POR CULTIVAR ---')
```

```
print(pd.DataFrame(resultados_outliers))
```

```
# =====
```

```
# ITEM (c): Boxplots Comparativos
```

```
# =====
```

```
fig, axes = plt.subplots(1, 3, figsize=(15, 5))
```

```
for i, var in enumerate(top_3_vars):
```

```
    sns.boxplot(
```

```
        x='cultivar',
```

```
        y=var,
```

```
        data=df,
```

```

ax=axes[i],

palette=['#D1C4E9', '#F8BBD0', '#B3E5FC'],

hue='cultivar',

legend=False,

)

axes[i].set_title(f'Boxplot: {var}', fontsize=12, weight='bold')

axes[i].set_xlabel('Cultivar', fontsize=10)


axes[i].set_ylabel(var, fontsize=10)

axes[i].grid(True, linestyle='--', alpha=0.5)

plt.tight_layout()

plt.show()

```



A análise combinada das métricas de dispersão indica que não existe um cultivar consistentemente mais homogêneo de forma universal; a estabilidade estrutural depende intrinsecamente da substância química avaliada e da lente analítica adotada. Enquanto o Cultivar A exibe a menor dispersão relativa em torno da média (o menor CV) para a maioria dos

compostos críticos, ele concentra, paradoxalmente, a maior incidência de valores atípicos (outliers) nas caudas da distribuição. Em contrapartida, o Cultivar C apresenta elevado controle em seus extremos (com ocorrência quase nula de outliers), a despeito de possuir uma variabilidade central superior em determinados compostos. Conclui-se que a classificação de homogeneidade demanda avaliações individualizadas por variável química.

Questão 6 : Forma da Distribuição e Normalidade

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
from scipy.stats import shapiro
```

```
# 1. Carregando os dados e definindo as variáveis
```

```
df = pd.read_csv('wine_dataset.csv')
```

```
vars_q6 = ['magnesium', 'malic_acid', 'proanthocyanins', 'hue']
```

```
# =====
```

```
# LETRA A: CÁLCULO E CLASSIFICAÇÃO DA ASSIMETRIA
```

```
# =====
```

```
print("--- LETRA A: CLASSIFICAÇÃO DE ASSIMETRIA (SKEWNESS) ---")
```

```
assimetria = df[vars_q6].skew()
```

```
def classificar_assimetria(valor):
```

```
    if valor > 0.5:
```

```

        return 'Assimétrica à Direita (Positiva)'

    elif valor < -0.5:

        return 'Assimétrica à Esquerda (Negativa)'

    else:

        return 'Aproximadamente Simétrica'

classificacao = assimetria.apply(classificar_assimetria)

for var, classe in classificacao.items():

    print(f"{var}: {assimetria[var]:.3f} -> {classe}")

# =====

# LETRA B: HISTOGRAMAS COM KDE

# =====

fig, axes = plt.subplots(2, 2, figsize=(12, 9))

axes = axes.flatten()

paleta = ['#D1C4E9', '#F8BBD0', '#B3E5FC', '#B2DFDB']

for i, var in enumerate(vars_q6):

    sns.histplot(

        data=df, x=var, kde=True, ax=axes[i],

        color=paleta[i], edgecolor='black'

    )

```

```
axes[i].set_title(f'Histograma e KDE: {var}', weight='bold')
```

```
axes[i].set_xlabel(var)
```

```
axes[i].set_ylabel('Frequência')
```

```
plt.tight_layout()
```

```
plt.show()
```

```
# =====
```

```
# LETRA C: TESTE DE SHAPIRO-WILK
```

```
# =====
```

```
print("\n--- LETRA C: TESTE DE SHAPIRO-WILK ---")
```

```
variaveis_teste = ['hue', 'malic_acid']
```

```
for var in variaveis_teste:
```

```
    stat, p_valor = shapiro(df[var])
```


```
    print(f"{var} | W: {stat:.4f} | P-valor: {p_valor:.6f}")
```

```
    if p_valor > 0.05:
```

```
        print(f"-> Resultado: {var} tem Distribuição Normal ( $p > 0.05$ )")
```

```
    else:
```

```
        print(f"-> Resultado: {var} NÃO tem Distribuição Normal ( $p < 0.05$ )")
```



1. Escolha da Medida de Tendência Central

- **Para *magnesium*, *malic_acid* e *proanthocyanins***: A mediana firma-se como o estimador mais robusto. Os cálculos atestam assimetria à direita (assimetria positiva) e os histogramas revelam caudas alongadas, o que torna a média aritmética altamente suscetível à distorção por valores extremos. A mediana reflete o verdadeiro centro da distribuição sem absorver o viés dos dados atípicos.
- **Para *hue***: A média caracteriza-se como a medida ideal, dado que a variável demonstrou um coeficiente de assimetria próximo a zero. Por apresentar uma distribuição aproximadamente simétrica e isenta de caudas pesadas, a média consolida perfeitamente o centro de gravidade dos dados.

2. Avaliação de Normalidade (Teste de Shapiro-Wilk)

Ao aplicar o teste estatístico de Shapiro-Wilk para verificar a normalidade das distribuições em um nível de significância de 5% ($\alpha = 0,05$):

- **malic_acid**: Apresentou um p-valor de 0,0000 ($p < 0,05$), levando à rejeição categórica da Hipótese Nula (H_0). Isso valida rigorosamente a evidência visual do histograma, comprovando que a distribuição **não é normal**.
- **hue**: Embora o histograma sugira um formato visual de sino, o teste resultou em um p-valor de 0,0174 ($p < 0,05$). Isso demonstra que a variável falha no teste rigoroso de aderência, provando estatisticamente que a simetria visual, por si só, não garante a normalidade, e a hipótese de distribuição normal também deve ser **rejeitada** para esta variável.

Questão 7 : Correlação, Significância e Redundância

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import pearsonr, shapiro, spearmanr, kendalltau

# Carregando os dados
df = pd.read_csv('wine_dataset.csv')
colunas_numericas = df.select_dtypes(include=[np.number]).columns
corr_matrix = df[colunas_numericas].corr()

# =====
# LETRA A: Filtrando pares fortes
# =====
pares = corr_matrix.unstack().dropna()
pares_fortes = pares[(abs(pares) > 0.7) & (pares != 1.0)]
pares_unicos = pares_fortes.drop_duplicates()

# Excluindo o par proibido
pares_finais = pares_unicos.drop(
    labels=[('flavanoids', 'total_phenols'), ('total_phenols', 'flavanoids')],
    errors='ignore'
)

# Descobrindo automaticamente o par com a MAIOR correlação
par_maior_corr = pares_finais.abs().idxmax()
var1, var2 = par_maior_corr
r_max = pares_finais[par_maior_corr]

print("--- RESULTADOS DA QUESTÃO 7 ---")
print(f"Par de maior correlação: {var1} e {var2} (r = {r_max:.4f})\n")
```

```

# =====
# LETRA B: Estatística t e Scipy
# =====
n = len(df)
t_manual = r_max * np.sqrt(n - 2) / np.sqrt(1 - (r_max ** 2))
r_scipy, p_pearson = pearsonr(df[var1], df[var2])

print("--- LETRA B ---")
print(f"Estatística t (Manual): {t_manual:.4f}")
print(f"P-valor (SciPy): {p_pearson:.2e}\n")

# =====
# LETRA C: Normalidade, Spearman e Kendall
# =====
print("--- LETRA C ---")
stat1, p1 = shapiro(df[var1])
stat2, p2 = shapiro(df[var2])

print(f"Shapiro-Wilk ({var1}): p-valor = {p1:.6f}")
print(f"Shapiro-Wilk ({var2}): p-valor = {p2:.6f}")

if p1 < 0.05 or p2 < 0.05:
    r_spearman, _ = spearmanr(df[var1], df[var2])
    r_kendall, _ = kendalltau(df[var1], df[var2])
    print(f"\n-> Pelo menos uma variável não é normal. Calculando alternativas:")
    print(f"-> Spearman: {r_spearman:.4f}")
    print(f"-> Kendall: {r_kendall:.4f}\n")

# =====
# LETRA D: Heatmap e Scatter Plot
# =====
print("--- LETRA D ---")
print("Gerando gráficos... (Feche a janela para encerrar)")

paleta = ['#D1C4E9', '#F8BBD0', '#B3E5FC']
plt.figure(figsize=(14, 6))

# 1. Heatmap
plt.subplot(1, 2, 1)
sns.heatmap(corr_matrix, annot=False, cmap='Purples', linewidths=0.5)
plt.title('Heatmap da Matriz de Correlação', weight='bold')

# 2. Scatter Plot com reta
plt.subplot(1, 2, 2)


```

```

sns.scatterplot(
    data=df, x=var1, y=var2, hue='cultivar',
    palette=paleta, edgecolor='black', alpha=0.8
)
sns.regplot(
    data=df, x=var1, y=var2, scatter=False,
    color='gray', line_kws={'linestyle':'--'}
)
plt.title(f'Dispersão com Reta Ajustada: {var1} x {var2}', weight='bold')

plt.tight_layout()
plt.show()

```



Interpretação Estatística dos Resultados: A varredura correlacional identificou o par flavanoids e od280/od315_of_diluted_wines como detentor da maior correlação positiva, indicando forte colinearidade ($r = 0,7872$). A validação empírica através do teste paramétrico de significância resultou em um valor-p infinitesimal ($8,60 \times 10^{-39}$), permitindo rejeitar H_0 sob $\alpha = 0,05$ e constatar que a correlação linear é matematicamente robusta e distinta de zero. Contudo, a verificação de pressupostos pelo teste de Shapiro-Wilk assinalou violações na premissa de normalidade (ambos com p-valor $< 0,05$), tornando a métrica de Pearson metodologicamente inadequada. A aplicação contingencial de estimadores não paramétricos manteve a direção positiva e expressiva da relação, resultando em correlações consistentes tanto no teste de Spearman quanto no de Kendall.

Questão 8 : Teste de Hipótese entre Dois Grupos

```
import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns

from scipy.stats import shapiro, levene, kruskal


# 1. Carregando os dados e separando os grupos (Letra A)

df = pd.read_csv('wine_dataset.csv')

df_bc = df[df['cultivar'].isin(['Cultivar B', 'Cultivar C'])]

magnesium_B = df[df['cultivar'] == 'Cultivar B']['magnesium']

magnesium_C = df[df['cultivar'] == 'Cultivar C']['magnesium']


print("--- LETRA B: PRESSUPOSTOS ---")


# 2. Teste de Normalidade (Shapiro-Wilk)

stat_b, p_shapiro_b = shapiro(magnesium_B)

stat_c, p_shapiro_c = shapiro(magnesium_C)

print(f"Shapiro (Cultivar B): p-valor = {p_shapiro_b:.6f}")

print(f"Shapiro (Cultivar C): p-valor = {p_shapiro_c:.6f}")


# 3. Teste de Homogeneidade (Levene)

stat_lev, p_levene = levene(magnesium_B, magnesium_C)

print(f"Levene (Variâncias): p-valor = {p_levene:.6f}")
```

```
print("\n--- LETRA C: TESTE DE HIPÓTESE ---")

# 4. Teste de Kruskal-Wallis (já que Shapiro falhou)

stat_kruskal, p_kruskal = kruskal(magnesium_B, magnesium_C)

print(f"Kruskal-Wallis: p-valor = {p_kruskal:.6f}")

if p_kruskal < 0.05:

    print("-> Resultado: Rejeitamos H0. EXISTE diferença significativa no magnésio.")

else:

    print("-> Resultado: Não rejeitamos H0. NÃO existe diferença significativa.")


# 5. Boxplot (Letra D)

plt.figure(figsize=(8, 6))

sns.boxplot(

    data=df_bc, x='cultivar', y='magnesium', palette=['#F8BBD0', '#B3E5FC']


)

plt.title('Comparação de Magnésio: Cultivar B vs Cultivar C', weight='bold')

plt.xlabel('Cultivar')

plt.ylabel('Teor de Magnésio')

plt.show()
```



C)

A eleição do teste não paramétrico de Kruskal-Wallis fundamenta-se na violação do pressuposto de normalidade atestado pelo teste de Shapiro-Wilk ($p\text{-valor} < 0,05$), que invalida o uso do Teste t de Student paramétrico. Em contrapartida, o teste de Levene confirmou a homocedasticidade das variâncias ($p = 0,438317$, maior que $\alpha = 0,05$), consolidando o cenário estrutural idôneo para o Kruskal-Wallis operar. A aplicação do teste resultou em $p\text{-valor} = 0,000566$. Sendo estritamente inferior ao nível de significância estipulado ($\alpha = 0,05$), rejeita-se a Hipótese Nula (H_0), documentando-se divergência estatisticamente significativa no teor de magnésio entre as variedades.

D)

A inspeção da amostragem revela contrastes substanciais no perfil de retenção de magnésio entre as cepas avaliadas. O Cultivar C caracteriza-se por originar produtos com densidade deste mineral em patamares sistemicamente mais altos e com distribuição previsível ao longo dos lotes. Em oposição, o Cultivar B registra uma concentração de base retraída, ainda que apresente ocorrências episódicas de garrafas com picos expressivos (outliers). Caso o objetivo

produtivo da vinícola priorize a constância e níveis elevados deste marcador, o Cultivar C representa a variedade agrícola estatisticamente superior e de menor variabilidade.

Questão 9 : ANOVA/Kruskal-Wallis com Post-Hoc

```
import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns

from scipy.stats import shapiro, levene, kruskal, mannwhitneyu

import itertools


# Carregando os dados

df = pd.read_csv('wine_dataset.csv')


# Separando o malic_acid para os três cultivares

malic_A = df[df['cultivar'] == 'Cultivar A']['malic_acid']

malic_B = df[df['cultivar'] == 'Cultivar B']['malic_acid']

malic_C = df[df['cultivar'] == 'Cultivar C']['malic_acid']


alfa = 0.05


print("--- LETRA A: TESTES DE NORMALIDADE (SHAPIRO-WILK) ---")

grupos = {'Cultivar A': malic_A, 'Cultivar B': malic_B, 'Cultivar C': malic_C}

todos_normais = True
```

```

for nome, dados in grupos.items():

    stat, p_val = shapiro(dados)

    if p_val >= alfa:

        print(f"{nome}: p-valor = {p_val:.6f} -> NORMAL (p >= 0.05)")

    else:

        print(f"{nome}: p-valor = {p_val:.6f} -> NÃO NORMAL (p < 0.05)")

    todos_normais = False


print("\n--- LETRA A: HOMOGENEIDADE (LEVENE) ---")

stat_lev, p_levene = levene(malic_A, malic_B, malic_C)

if p_levene >= alfa:

    print(f"Levene: p-valor = {p_levene:.6f} -> VARIÂNCIAS HOMOGENEAS (p >= 0.05)")

else:

    print(f"Levene: p-valor = {p_levene:.6f} -> VARIÂNCIAS NÃO HOMOGENEAS (p < 0.05)")


print("\n--- LETRA B: DECISÃO E TESTE GLOBAL ---")

if todos_normais and p_levene >= alfa:

    print("Veredito: Todos os pressupostos atendidos. Escolha: ANOVA.")

else:

    print("Veredito: Pelo menos um pressuposto falhou. Escolha: KRUSKAL-WALLIS.")

    stat_k, p_kskal = kruskal(malic_A, malic_B, malic_C)

    print(f"Resultado Kruskal-Wallis: p-valor = {p_kskal:.2e}")

```

```

print("\n--- LETRA C: TESTE POST-HOC (Mann-Whitney ajustado) ---")

comparacoes = [('Cultivar A', malic_A), ('Cultivar B', malic_B), ('Cultivar C', malic_C)]

pares = list(itertools.combinations(comparacoes, 2))

multiplicador = len(pares)

for (nome1, dados1), (nome2, dados2) in pares:

    stat, p_bruto = mannwhitneyu(dados1, dados2, alternative='two-sided')

    p_ajustado = min(p_bruto * multiplicador, 1.0) # Correção de Bonferroni

    significativo = "SIM" if p_ajustado < alfa else "NÃO"

    print(f'{nome1} vs {nome2} | p-ajustado: {p_ajustado:.4f} | Diferença Significativa? {significativo}')

print("\n--- LETRA D: GERANDO BOXPLOT ---")

print("Feche a janela do gráfico para encerrar o programa.")

plt.figure(figsize=(8, 5))

sns.boxplot(

    x='cultivar',

    y='malic_acid',

    data=df,

    palette=['#D1C4E9', '#F8BBD0', '#B3E5FC']

)


plt.title('Comparação de Ácido Málico entre Cultivares', weight='bold')

```

```
plt.ylabel('Ácido Málico')
```

```
plt.xlabel('Cultivar')
```

```
plt.show()
```



B)

A escolha do teste de Kruskal-Wallis é a correta, pois houve a quebra de dois pressupostos obrigatórios para o uso da ANOVA. O teste de Shapiro-Wilk comprovou que os dados de ácido málico não seguem uma distribuição normal nos Cultivares A e B (ambos com $p\text{-valor} < 0,05$). Além disso, o teste de Levene confirmou que as variâncias não são homogêneas ($p\text{-valor} = 0,002$). Sendo assim, a única alternativa estatisticamente válida é o teste não-paramétrico de Kruskal-Wallis.

C)

O teste de Tukey HSD sugerido no enunciado é inadequado para este cenário, pois ele é estritamente paramétrico e exige o uso da ANOVA. Para acompanhar o Kruskal-Wallis, apliquei o teste post-hoc de Mann-Whitney par a par com a correção de Bonferroni.

O resultado mostrou que o Cultivar C é significativamente diferente do A e do B. No entanto, na comparação direta entre o Cultivar A e o Cultivar B, o p-valor ajustado foi de 0,0522. Como este valor é maior que o alfa de 0,05, não há diferença estatística significativa no ácido málico entre o Cultivar A e o Cultivar B.

D)

As métricas evidenciam que a variedade do Cultivar C diverge estruturalmente das restantes, consolidando níveis substancialmente majorados de ácido málico nas formulações. Os Cultivares A e B configuram-se como perfis de acidez mais contidos e mutuamente análogos. Desta forma, caso o delineamento do produto final demande acidez málica predominante e encorpada, a escolha restringe-se objetivamente ao Cultivar C, enquanto as alternativas A e B equivalem-se operacionalmente em matéria deste componente

Questão 10 : Questão Integradora

```
import pandas as pd
import numpy as np
from scipy.stats import shapiro, levene, f_oneway, kruskal

# Carregando os dados originais
df = pd.read_csv('wine_dataset.csv')

# =====
# LETRA A: Amostra Estratificada (60%, random_state=7)
# =====
amostra_60 = df.groupby('cultivar').sample(frac=0.6, random_state=7)

print("--- LETRA A: CONTAGEM DA AMOSTRA (60%) ---")
print(amostra_60['cultivar'].value_counts())

# =====
# LETRA B: Matriz de Correlação e Variáveis Mais Redundantes
# =====
colunas_num = amostra_60.select_dtypes(include=[np.number]).columns
corr_matrix = amostra_60[colunas_num].corr()

pares = corr_matrix.abs().unstack().dropna()
pares = pares[pares != 1.0].drop_duplicates()
```

```

# Excluindo os pares já usados na Questão 7
pares_excluir = [
    ('flavanoids', 'total_phenols'), ('total_phenols', 'flavanoids'),
    ('flavanoids', 'od280/od315_of_diluted_wines'), ('od280/od315_of_diluted_wines', 'flavanoids')
]
pares_filtrados = pares.drop(labels=pares_excluir, errors='ignore')

par_redundante = pares_filtrados.idxmax()
r_max = pares_filtrados.max()

print("\n--- LETRA B: PAR MAIS REDUNDANTE ---")
print(f"Variáveis: {par_redundante[0]} e {par_redundante[1]} (r = {r_max:.4f})")

# =====
# LETRA C: Teste estatístico para o 'alcohol'
# =====
alc_A = amostra_60[amostra_60['cultivar'] == 'Cultivar A']['alcohol']
alc_B = amostra_60[amostra_60['cultivar'] == 'Cultivar B']['alcohol']
alc_C = amostra_60[amostra_60['cultivar'] == 'Cultivar C']['alcohol']

alfa = 0.05
todos_normais = True

print("\n--- LETRA C: PRESSUPOSTOS DO TEOR ALCOÓLICO ---")
grupos_alc = {'Cultivar A': alc_A, 'Cultivar B': alc_B, 'Cultivar C': alc_C}

for nome, dados in grupos_alc.items():
    stat, p_val = shapiro(dados)
    if p_val >= alfa:
        print(f"Shapiro ({nome}): p-valor = {p_val:.6f} -> Normal")
    else:
        print(f"Shapiro ({nome}): p-valor = {p_val:.6f} -> Não Normal")
        todos_normais = False

stat_lev, p_levene = levene(alc_A, alc_B, alc_C)
if p_levene >= alfa:
    print(f"Levene: p-valor = {p_levene:.6f} -> Variâncias Homogêneas")
else:
    print(f"Levene: p-valor = {p_levene:.6f} -> Variâncias Não Homogêneas")

print("\n--- LETRA C: TESTE ESCOLHIDO ---")
if todos_normais and p_levene >= alfa:
    print("Veredito: Usando ANOVA.")

```

```

stat_test, p_test = f_oneway(alc_A, alc_B, alc_C)
print(f"ANOVA p-valor: {p_test:.2e}")
else:
    print("Veredito: Usando KRUSKAL-WALLIS.")
    stat_test, p_test = kruskal(alc_A, alc_B, alc_C)
    print(f"Kruskal-Wallis p-valor: {p_test:.2e}")

```

B&C)

Na amostra estratificada elaborada, o par remanescente de maior redundância é composto pelas variáveis *total_phenols* e *od280/od315_of_diluted_wines*, exibindo um coeficiente de correlação consistente de $r = 0,7047$. No cômputo inferencial (Item C), a normalidade foi atestada para todos os três cultivares por meio do teste de Shapiro-Wilk (todos apresentando $p \geq 0,05$), assim como a homogeneidade de variâncias foi confirmada via teste de Levene. Sendo os pressupostos integralmente validados, elegeu-se o teste paramétrico ANOVA, o qual atestou diferença de variância altamente significativa, retornando p-valor igual a $2,02 \times 10^{-23}$.

D)

A amostra estratificada manteve a representatividade estrutural da população, mitigando vieses distributivos ao ancorar os estratos. A elevada redundância detectada ($r = 0,7047$) entre *total_phenols* e *od280/od315_of_diluted_wines* fornece embasamento estatístico prático para a supressão de um destes ensaios laboratoriais na rotina operacional, otimizando os custos diretos da vinícola sem perdas relevantes de informação descritiva. Adicionalmente, a rejeição taxativa da Hipótese Nula pela ANOVA (com p-valor $< 0,05$) corrobora a existência de perfis alcoólicos marcante e estruturalmente desiguais entre as variedades. Esta assimetria química mensurável e validada confere à diretoria respaldo metodológico seguro para a implementação efetiva da política de precificação diferenciada.

Conversa com IA (também em PDF anexado):
<https://share.gemini.google/UH9dqPUWKGFr>